

Stroke Prediction Dataset 中風預測分析

資料探勘期中報告

報告人：王俊詠
學號：11127004

研究主題與目的

核心目標

透過資料探勘流程，建立預測中風風險的分類模型。

比較重點

評估不同演算法在極度不平衡醫療資料上的實際表現。



醫療篩檢的關鍵挑戰

- 1. 「寧可誤警，不可漏判」**
中風為高風險醫療事件，漏判 (False Negative) 的後果極為嚴重。
- 2. 準確率陷阱 (Accuracy Paradox)**
若模型將所有人皆預測為未中風，準確率依然極高，但失去篩檢意義。
- 3. 本研究評估核心：**
捨棄單純看 Accuracy，極度重視 **Recall (召回率)** 與 **FN (漏判數)**。

Dataset 資料集介紹

5,110

資料規模
(筆病患紀錄)

12

特徵維度
(原始欄位)



二元分類
(Binary Classification)

stroke

目標變數
(0=未中風，1=中風)



基本人口

age (年齡)

gender (性別)



健康狀況

hypertension (高血壓)

heart_disease (心臟病)

avg_glucose_level (平均血糖)

bmi (身體質量指數)



生活型態


ever_married (已婚)

work_type (工作)

Residence_type (居住地)

smoking_status (吸菸)

資料視覺化：類別嚴重不平衡



未中風 (stroke=0) 共 4,861 人


95.1%

中風 (stroke=1) 僅 249 人

4.9%

建模挑戰：極端的不平衡導致模型極易產生偏誤，傾向將所有樣本預測為未中風。必須導入特定技術來強化少數類別的權重。

資料視覺化：年齡與中風的關聯



年齡中位數差異顯著

- 未中風族群中位數：約 40 多歲
- 中風族群中位數：約 70 歲左右

臨床意義

隨著年齡增加，血管老化與慢性疾病風險上升，完全符合醫療常識。

特徵重要性

- 年齡是本資料集中與中風最相關的特徵之一。

資料前處理：Missing Value 缺失值處理

檢查發現



僅 bmi 欄位存在
201 筆缺失值。

處理策略



平均值填補
(Mean Imputation)


```
df['bmi'].fillna(  
df['bmi'].mean())
```

為何不刪除？



為了保留全部 5,110
筆寶貴樣本，避免因
刪除包含NaN的資料，
導致原本僅有 4.9%
的中風個案進一步流
失。

Correlation Analysis 相關性分析




與 Stroke (中風) 正相關最高的前四名特徵：

1. Age (年齡) : 0.25 (最強訊號)



2. Hypertension (高血壓) : 0.13



3. Heart Disease (心臟病) : 0.13



4. Avg Glucose Level (平均血糖) : 0.13



結論：年齡、慢性疾病與代謝指標皆與中風呈現正相關，但相關係數不高，仍需結合多個特徵進行預測。

One-Hot Encoding 編碼轉換

轉換前

12 個類別
與數值欄位



One-Hot
Encoding
(drop_first=True)

將文字型類別資料轉換為
數值格式。避免虛擬變數
陷阱造成的共線性問題。

轉換後

擴增為 18
個特徵欄位

0	0	0	1
0	1	0	1
1	0	1	0
0	1	1	1

新增欄位範例：
gender_Male
smoking_status_smokes
work_type_Private

Normalization 標準化

轉換前
(尺度差異極大)



Age




Avg Glucose



MinmaxScaler

轉換後
(尺度一致)



目的

消除不同特徵間的尺度差異。

重要性

對於以距離計算為核心的模型 (如 KNN)，標準化能防止大數值特徵主導模型權重，確保所有特徵在同一起跑點上。

Machine Learning 模型建立與不平衡處理

資料切分 (Data Splitting)

80% 訓練集 (4088筆) / **20%** 測試集 (1022筆)
分層抽樣 (Stratified)：確保維持真實世界 **4.9%** 比例

3 種基礎分類模型

Logistic Regression (LR)

Random Forest (RF)

KNN

2 種對抗不平衡的策略 (僅套用於訓練集)


SMOTE (合成少數類別過採樣)

生成虛擬病患，將訓練集中風/未中風比例拉至 **1:1** (各 3889 筆)。

`class_weight='balanced'`

不生成資料，直接在演算法內大幅提高中風樣本的學習權重。

模型結果比較：Recall 為王




原始模型的致命傷

原始 RF 完全抓不到中風病患；
原始 LR 雖 Precision 達 1.0，但
Recall 僅 0.02 (幾乎全漏判)。

不平衡處理的巨大成效

LR + Balanced 與 LR + SMOTE
表現最為優異。Recall 皆高達
0.80：成功找出 80% 的真正中
風患者。

醫療情境關鍵指標分析：TP 與 FN



Worst Case (原始 RF)

漏診 (FN) 高達 **50 例**。所有中風病患皆被誤判為正常，模型完全不具篩檢價值。

Best Case (LR + Balanced / LR + SMOTE)

TP = 40 例 (成功檢出)

FN = 僅 **10 例** (嚴重漏診)

結論 (Trade-off)

雖然代價是 Precision 降至 0.14 (False Positive 增加)，但在醫療前線，降低 FN (漏診) 才是挽救生命的核心關鍵。原則是「寧可誤警，不可漏判」。

最佳推薦模型



推薦模型：Logistic Regression + `class_weight='balanced'`

1. 極大化召回率

Recall 高達 0.80，與 SMOTE 並列第一，將最致命的漏判率 (FN) 降至最低。

2. 無虛擬資料風險

僅靠調整權重，無需像 SMOTE 生成合成數據，方法更純粹、簡單且安全。

3. 高醫療解釋性

邏輯回歸的模型係數較容易解釋，可協助醫師理解年齡、血糖、高血壓等特徵對預測結果的影響。

研究限制與未來展望



1. 擴充臨床特徵

現有資料僅含基本人口及健康指標。未來應納入實際血壓、膽固醇、家族病史與用藥紀錄等數據，以提升模型預測力。



2. 最佳化超參數

導入 GridSearchCV，尋找最佳參數，進一步平衡 Precision 與 Recall。



3. 導入進階演算法

評估 XGBoost、LightGBM 等進階模型表現，並比較 SMOTETomek、SMOTEENN 等混合型資料不平衡處理技術。



4. 調整決策閾值

因應醫療篩檢需求，調整預設 0.5 之分類門檻，以更精確地識別潛在高風險族群。



Thank you!
