

第 1 頁：封面

大家好，今天我要報告的主題是**中風預測分析**。

這份報告主要是針對中風預測資料集進行分析，並比較不同機器學習模型在醫療不平衡資料上的表現。

第 2 頁：研究主題與目的

本研究的核心目標，是建立一個可以預測中風風險的分類模型。

在一般分類問題中，我們常常會先看準確率。但是在醫療篩檢情境中，只看準確率可能會產生誤導。

因為中風是高風險醫療事件，如果模型把真的有中風風險的人判斷成沒有風險，這種情況在醫療上是非常嚴重，因為可能會讓病患錯過進一步及時檢查與治療。

所以本研究的評估核心而是更重視 **Recall**，也就是召回率，以及 **FN**，漏判人數。

第 3 頁：Dataset 資料集介紹

本研究使用的是 Stroke Prediction Dataset。

資料集共有 **5110 筆病患資料**，原始欄位共有 **12 個**，任務類型是二元分類。

目標變數是 stroke，其中：

stroke = 0 代表未中風，

stroke = 1 代表中風。

資料欄位大致分成三類。

第一類是基本人口資料，例如年齡和性別。

第二類是健康狀況資料，例如高血壓、心臟病、平均血糖值和 BMI。

第三類是生活型態資料，例如婚姻狀態、工作型態、居住地類型和吸菸狀態。

第 4 頁：資料視覺化：類別嚴重不平衡

這一頁可以看到，資料集中未中風的人有 4861 人，占 95.1%；中風的人只有 249 人，占 4.9%。

這代表資料存在非常嚴重的類別不平衡問題。會造成如果模型全部都預測成未中風，它的 Accuracy 仍然可能接近 95%。但是這樣的模型並沒有實際醫療價值。

第 5 頁：資料視覺化：年齡與中風的關聯

接著觀察年齡與中風之間的關係。

從箱型圖可以看出，未中風族群的年齡中位數大約在 40 多歲，而中風族群的年齡中位數大約在 70 歲左右。

也就是說，中風族群整體年齡明顯較高。

這代表在這份資料中，年齡與中風結果有明顯關聯。

隨著年齡增加，血管老化、慢性疾病與代謝問題的風險也可能提高，因此年齡是本資料集中與中風最相關的特徵之一。

第 6 頁：Missing Value 缺失值處理

在資料前處理階段，發現 bmi 欄位有缺失值，共有 201 筆。

處理方式是使用平均值填補，這樣做的原因是，希望保留全部 5110 筆資料。

因為中風樣本本來就只有 249 筆，占比只有 4.9%。

如果直接刪除含有缺失值的資料，可能會讓少數類別樣本更少，進一步加重資料不平衡問題。

第 7 頁：Correlation Analysis 相關性分析

接著進行相關性分析，觀察數值欄位和 stroke 之間的關係。

從結果來看，與 stroke 正相關最高的特徵是 Age，相關係數約為 0.25。

接著是 Hypertension 高血壓、Heart Disease 心臟病、Avg Glucose Level 平均血糖值，它們和中風的相關係數都是 0.13。

BMI 的相關性比較弱，大約是 0.039。

這代表年齡、慢性疾病與代謝指標都和中風有一定關聯。但是整體相關係數其實不算非常高，所以不能只靠單一欄位判斷中風風險。因此，後續需要結合多個特徵，讓機器學習模型從整體資料中學習更完整的判斷規則。

第 8 頁：One-Hot Encoding 編碼轉換

因為資料中有許多文字型欄位，例如性別、工作型態、吸菸狀態等。但是模型不能直接處理文字資料，所以需要先將它們轉換成數值格式。

透過 One-Hot Encoding。經過轉換後，如 gender、work_type、smoking_status 這些類別欄位，都會被轉成 0 或 1 的數值欄位，原本 12 個欄位變成 18 個特徵欄位。。

第 9 頁：Normalization 標準化

接著進行標準化處理。

不同欄位的數值範圍差異很大，例如年齡大約從 0 到 82，而平均血糖值大約從 55 到 271。如果不進行標準化，數值範圍較大的欄位可能會對模型產生過大影響。

所以透過 MinMaxScaler，把所有特徵縮放到 0 到 1 之間。

第 10 頁：Machine Learning 模型建立與不平衡處理

這一頁說明模型建立流程與不平衡資料處理方式。

首先，將資料切分成訓練集和測試集。

其中 80% 訓練集，共 4088 筆資料；另外 20%測試集，共 1022 筆資料。

切分時使用分層抽樣，目的是讓訓練集和測試集都維持接近原始資料中 4.9% 的中風比例。

模型方面，本研究比較三種基礎分類模型，分別是邏輯回歸、Random Forest 和 KNN。

由於資料中的中風樣本只有 4.9%，屬於嚴重不平衡資料，所以加入兩種處理不平衡的策略。

第一種是 SMOTE，它是資料層級的方法，會在訓練集中合成少數類別樣本，讓中風和未中風比例接近 1 比 1。

SMOTE 只套用在訓練集，不套用在測試集，這樣才能避免資料洩漏。

第二種是權重調整法，它是演算法層級的方法，不會產生新的資料，而是在模型訓練時提高中風類別的學習權重。

第 11 頁：模型結果比較：Recall 為王

從圖中可以看到，Logistic Regression 的 Precision 是 1，但 Recall 只有 0.02。是因為它只預測出 1 位中風，而剛好預測正確，所以 Precision 變成 1。但是它漏掉了 49 位真正中風病患，所以 Recall 非常低。

Random Forest 的情況更嚴重，Recall 是 0，代表它完全沒有抓到中風病患。

相較之下，LR + Balanced 和 LR + SMOTE 的 Recall 都達到 0.80，是所有模型中最高的。也就是說，這兩個模型可以成功找出 80% 真正中風個案。

不過以 LR + Balanced 為例，它的 Precision 是 0.14，代表模型預測為中風的人當中，真正中風的比例約 14%，會有比較多誤警。但是它的 Recall 是 0.80，真正中風的病患中，有 80% 都被模型成功找出來。

因此，這個模型較適合作為初步風險篩檢工具，不是用來取代醫師診斷。

它透過快速模型預測，先找出可能屬於中風高風險的個案，再安排後續更詳細

的醫療檢查。

第 12 頁：醫療情境關鍵指標分析：TP 與 FN

這一頁

TP 代表真正中風，模型也成功預測為中風。

FN 則代表真正中風，模型卻預測為未中風，也就是漏判。

在醫療情境中，FN 是最危險的錯誤，病患可能因此錯過即時的治療及檢查。

從圖中看到，Random Forest 的 FN 是 50，也就是測試集中 50 位中風病患全部被漏判。LR 也漏判了 49 位，KNN 則漏判了 48 位，這些模型都不適合醫療篩檢。

相反地，LR + Balanced 和 LR + SMOTE 的 TP 都是 40，FN 都是 10。

也就是說，它們成功找出 40 位中風病患，並將漏判降低到 10 位。

雖然這讓 Precision 降低，誤判人數增加，但在醫療篩檢中，降低 FN 才是更重要的核心目標。

第 13 頁：最佳推薦模型

根據前面的結果，本研究最後推薦的模型是：

Logistic Regression + 權重調整法

選擇這個模型主要有三個原因。

第一，它的 Recall 達到 0.80，能成功找出 80% 的中風病患，並且和 SMOTE 並列第一，將最重要的漏判 FN 降到最低。

第二，它不需要像 SMOTE 一樣產生合成資料，只是透過調整類別權重來處理不平衡問題，因此方法比較單純，也比較安全。

尤其在醫療資料中，SMOTE 產生的合成樣本雖然是常見方法，但在解釋上仍然需要比較謹慎。

第三，Logistic Regression 的模型係數比較容易解釋，可以協助醫師理解年齡、血糖、高血壓等特徵對預測結果的影響。

雖然 LR + SMOTE 的 Recall 也同樣是 0.80，但考量到方法簡潔性、資料真實性與醫療解釋性，本研究最後選擇 LR + Balanced 作為最推薦模型。

第 14 頁：研究限制與未來展望

最後是研究限制與未來展望。

第一，目前資料集僅包含基本人口與健康指標。

未來可以加入更多臨床資料，例如實際血壓值、膽固醇、家族病史與用藥紀錄，讓模型有更多判斷依據。

第二，可以進行超參數最佳化。

例如使用 GridSearchCV 系統化尋找最佳參數組合，進一步平衡 Precision 和 Recall。

第三，可以嘗試更多進階演算法。

例如 XGBoost、LightGBM 等進階模型，也可以比較 SMOTETomek、SMOTEENN 等混合型不平衡處理技術。

第四，可以調整決策閾值。

目前模型通常使用 0.5 作為分類門檻，但在醫療篩檢情境中，可以根據需求調整 threshold，以更精確地找出潛在高風險族群。

第 15 頁：Thank You

以上是我的報告。

謝謝大家。