

神經網路中風預測分析

以 MLP 作為期末延伸主軸

Pipeline · MLPClassifier · OOF F2 Threshold Tuning

報告者：王俊詠

學號：11127004

期中建立基線，期末改以神經網路延伸

期中報告

- 1 平均補值、MinMaxScaler
- 2 比較 LR / RF / KNN
- 3 class_weight / SMOTE

期末重點

- 1 加入 Neural Network
- 2 比較非線性模型能力
- 3 仍需處理類別不平衡


本次延伸

- 1 MLPClassifier 作為主模型
- 2 GridSearchCV 搜尋 MLP 參數
- 3 OOF F2 選擇 MLP 門檻

延伸重點：以 MLP 神經網路為主，LR 作為可解釋基準模型。

資料集的核心難題：中風案例只占 4.87%

Dataset 視覺化：類別不平衡與主要風險特徵



資料共 5,110 筆；中風者僅 249 人（4.87%），且中風族群的年齡與血糖分布較高。

樣本數

5,110

健康與生活型態資料

中風案例

249

少數類別

中風比例


4.87%

Accuracy 容易被誤導

因此評估重點必須放在 Recall、Precision、F1/F2 與混淆矩陣。

視覺化顯示：風險集中在年齡與血糖等特徵

Dataset 視覺化：類別不平衡與主要風險特徵



資料共 5,110 筆；中風者僅 249 人 (4.87%)，且中風族群的年齡與血糖分布較高。

觀察到的趨勢

01

中風案例在高年齡區間較集中

02

平均血糖較高時，風險分布更明顯

03

單一特徵不足以診斷，需模型整合

隱藏趨勢不是「某特徵決定中風」，而是多個弱訊號共同累積。

缺失值與相關性：先修補資料，再避免過度解讀

相關性分析：數值特徵與中風

相關性僅表示線性關聯，不代表因果關係。



與 stroke 關聯較明顯：年齡 0.25、高血壓 0.13、心臟病 0.13、平均血糖 0.13

BMI 缺失值

201


使用訓練資料中位數補值

相關性分析結論

- 年齡、血糖與中風呈較明顯正向關係
- 相關性不代表因果關係
- 類別特徵仍需透過 One-Hot 納入模型

Pipeline 讓前處理只從訓練資料學習

資料前處理：缺失值、編碼轉換與標準化




One-Hot Encoding

原始模型特徵
10 欄

轉換後模型特徵
21 欄

Standardization



所有前處理皆包在 Pipeline 內，交叉驗證時只使用各折訓練資料估計參數。

數值

Median Imputation

StandardScaler

類別

Most-frequent

One-Hot Encoding


輸出

10 個原始特徵

21 個轉換特徵

重點：補值、編碼、標準化與模型一起交叉驗證，降低資料洩漏風險。

神經網路流程：測試集只在最後一次打開



訓練階段決定 MLP 架構、正則化與門檻，測試集只負責回答：神經網路能否泛化？

神經網路模型設計：以 MLP 處理表格型中風資料

主模型

MLP

多層感知器

資料型態

Tabular

非影像、非序列

調參目標

PR-AUC

適合不平衡資料

決策目標

F2

比 F1 更重視 Recall

為什麼用 MLP，不用 CNN/RNN？

- 資料是病患欄位，不是圖片，所以不需要 CNN。
- 資料沒有時間序列順序，所以不需要 RNN/LSTM。
- MLP 可學習欄位之間的非線性組合。

延伸重點

- 沿用 Pipeline：補值、One-hot、標準化都在 CV 內完成。
- 用 sample_weight 處理 stroke 類別稀少問題。
- 最後再用 OOF F2 選出較適合醫療任務的門檻。

期末主軸：用神經網路作為主要模型，Logistic Regression 保留為可解釋基準。

MLP GridSearchCV : 搜尋神經網路架構與正則化

候選架構

3

(32,), (64,), (64,32)

Activation

ReLU

另比較 tanh

CV

3-fold

StratifiedKFold

Scoring

PR-AUC

average_precision

搜尋參數

hidden_layer_sizes	(32,), (64,), (64, 32)
activation	relu / tanh
alpha	0.0001 / 0.001 / 0.01
learning_rate_init	0.001 / 0.01

BEST MLP

hidden layer	(64,)
activation	ReLU
alpha	0.0001
learning rate	0.001
CV PR-AUC	0.1639

PR-AUC 用來評估模型是否能在少數 stroke 類別上排序出較高風險者。

神經網路不能只看 0.5：中風預測需要召回導向門檻

MLP 輸出機率



調整分類門檻



降低漏判風險

預設門檻 0.5

FN = 33

只有 17 位中風者被抓到

OOB F2 門檻 0.245

FN = 11

39 位中風者被抓到

F2 比 F1 更重視 Recall，因此較符合醫療預警：寧可多一些誤報，也要少漏掉高風險個案。

OOF F2 選出 MLP 分類門檻 = 0.245

最佳 MLP 門檻

0.245

OOF F2-score 選出

測試 Recall


0.78

39 / 50 位中風個案

測試 F2-score


0.430

較重視 Recall



0.245 由訓練集 OOF F2-score 選出，測試集未參與門檻選擇。

神經網路混淆矩陣：門檻調整後明顯降低漏判



True Positive

成功抓到實際中風個案

39

False Negative

漏判人數由 33 降低至 11

11

False Positive


代價是誤警示增加

215

Recall = $39 / 50 = 0.78$; 測試集 $n = 1,022$
MLP 分類門檻 = 0.245

調低分類門檻後，模型適合作為初步風險預警工具，但仍需
搭配後續醫療評估。

結果分析：MLP 主模型與 LR benchmark 比較



測試集指標		
Metric	MLP	LR
Precision	.154	.161
Recall	.780	.800
F1	.257	.268
F2	.430	.445
PR-AUC	.274	.252
LR benchmark: threshold 0.268 FN 10 / FP 209 / PR-AUC 0.252		

判讀：MLP 的 PR-AUC 較高，代表風險排序能力有進步；但 Recall/F2 略低於 LR benchmark，所以不能說 MLP 神經網路全面勝出。

期中基準 vs 期末神經網路：保留脈絡，但主軸轉向 MLP

期中 Balanced LR

FP 251

FN 10

Recall 0.80

傳統 ML 基線：LR / RF / KNN 比較

期末 MLP Neural Network

FP 215

FN 11

Recall 0.78

期末主模型：非線性風險排序

注意：FP=251 是期中 Balanced LR；FP=209 是期末 LR benchmark + threshold 0.268。
本頁比較的是期中基線與期末 MLP，不是把 LR 當期末主模型。

神經網路主軸下的判讀：MLP 有進步，也有取捨

MLP PR-AUC

0.274

高於 LR 0.252

MLP Recall

0.78

中風 50 人抓到 39 人

MLP F2

0.430

略低於 LR 0.445

神經網路學到了什麼？

- 可捕捉特徵交互作用。
- PR-AUC 提升，風險排序更有訊號。
- 門檻調整後，更像醫療預警器。

還需要注意什麼？

- stroke 樣本少，MLP 神經網路仍受類別不平衡影響。
- Recall/F2 尚未明顯贏過 LR。
- 未來可加入校準與成本敏感訓練。

因此本期末報告以 MLP 為主模型，並用 LR benchmark 作為判斷 MLP 神經網路成效的參考線。

結論：期末以神經網路延伸中風預測

- 01 MLP 適合這份表格型資料，可學習非線性特徵組合。
- 02 經 GridSearchCV 與 OOF F2 門檻調整後，MLP 測試 Recall 達 0.78。
- 03 MLP 的 PR-AUC 0.274 高於 LR benchmark 0.252，但 Recall/F2 仍略低於 LR benchmark。
- 04 實務上可把 MLP 作為風險排序工具，後續再搭配醫師檢查與更多資料驗證。

未來應用

1. 建立初步風險預警
2. 優先安排高風險檢查
3. 增加資料後重新訓練 MLP
4. 加入機率校準
5. 加入成本敏感學習

隱藏趨勢

中風不是單一欄位決定，而是年齡、健康指標
與生活背景共同累積的風險。

Thank you